TTS 五大方向总结

论文名称	1. 极速合成 (Fast TTS)	2. 低资源合成 (Low-Resource TTS)	3. 鲁棒性提升 (Robust TTS)	4. 富有表现力 (Expressive TTS)	5. 自适应/声音克隆 (Adaptive TTS)
VITS	**并行端到端生成**：采用非自回归流模型并行生成，大幅提升了推理速度。	—	—	**随机时长预测器与VAE**：成功捕捉语音中的节奏和音高变化，解决了一段文本有多种自然读法的“一对多”映射问题。	—
VALL-E	—	—	—	**基于采样的多样化与情感保留**：利用语言模型的采样机制生成多样化结果，并且能够在生成时保留提示音频（Prompt）中的原始声学环境（如混响）和说话人情感。	**语音大模型**：将TTS视为**条件语言建模任务**，产生**上下文学习** 能力。只需3秒音频提示，无需微调即可实现Zero-shot零样本个性化声音克隆。
YourTTS	—	**多语言知识迁移**：通过**多语言联合训练**，能在低资源的小语种中实现多说话人Zero-shot合成。	—	—	**说话人一致性损失与高效微调**：引入外部说话人嵌入和**SCL损失**，不仅实现了出色的Zero-shot多说话人TTS和声音转换，还能在遇到全新录音环境时，仅用不到1分钟的音频实现极速微调自适应。
NaturalSpeech	—	—	**全端到端与可微时长预测**：构建真正的全端到	**双向先验/后验与记忆VAE**：通过预训练音素提取先验，用记忆	—

论文名称	1. 极速合成 (Fast TTS)	2. 低资源合成 (Low-Resource TTS)	3. 鲁棒性提升 (Robust TTS)	4. 富有表现力 (Expressive TTS)	5. 自适应/声音克隆 (Adaptive TTS)
			端模型以消除训练与推理的误差累积；用“可微时长预测器”代替注意力机制进行严格对齐，彻底解决漏读、重复读的鲁棒性问题。	VAE简化后验，并用流模型双向拉近两者距离，从而极大缓解一对多映射问题，合成媲美人类自然度的语音。	
NaturalSpeech 2	—	—	**非自回归扩散模型**：弃用了自回归模型和离散Token，改用基于连续向量的**非自回归潜在扩散模型**，从根本上避免了长序列自回归造成的误差传播和结巴问题。	**零样本歌声合成与丰富韵律**：借助扩散模型和连续向量的强大生成能力，不仅能生成具有丰富韵律的语音，还能仅凭语音提示实现Zero-shot的歌声合成。	**语音提示与上下文学习**：在时长/音高预测器和扩散模型中引入了语音提示机制，使其能够捕捉野生大规模数据中的音色和风格实现Zero-shot合成。