# TTS 模型架构总结

| 论文名称 | 1. Text Analysis | 2. Acoustic Model | 3. Vocoder |
| --- | --- | --- | --- |
| **VALL-E** | **G2P + 提示构建**：将输入文本转化为音素，并拼接参考音频的音素作为 Prompt。 | **神经 Codec 语言模型 (AR + NAR)**：将 TTS 视为语言建模任务。自回归 (AR) 模型预测第一层离散 Token，非自回归 (NAR) 模型预测后续七层 Token。 | **EnCodec Decoder**：接收预测的 8 层离散声学 Token，直接还原出语音波形。 |
| **VITS** | - | **Transformer 文本编码器 + MAS**：输入音素序列，通过 MAS 动态搜索文本和隐变量的最佳对齐。<br>**随机时长预测器 + 归一化流 (Normalizing Flow)**：用 Flow 增加先验分布的表达能力，并预测多样化的发音时长。 | **解码器 ( HiFi-GAN V1)**：将经过时长扩展的隐变量直接上采样生成语音波形。 |
| **YourTTS** | **字符级文本编码器 + 语言嵌入**：直接输入字符，并拼接可训练的**语言向量**以支持多语种。 | **流解码器 (Flow) + 随机时长预测器**：基于 VITS 架构，通过全局条件机制融入外部说话人特征。 | **解码器 (HiFi-GAN)**：与 VITS 类似，从潜在变量生成波形，实现端到端优化。 |
| **NaturalSpeech** | **大规模混合音素预训练**：使用海量文本数据对音素编码器进行预训练 **（利用MLM）**，提取更强大的文本表征。 | **双向先验/后验流 (Flow) + 可微时长预测器**：通过可微的上采样层消除时长预测的误差，并用 Flow 拉近文本先验和语音后验的距离。 | **带记忆机制的 VAE 解码器**：不再直接用隐变量生成波形，而是用其作为 Query **寻址记忆库**，再由解码器生成波形。 |
| **NaturalSpeech 2** | **音素编码器 + 上下文提示学习**：引入语音提示机制来学习参考音频的上下文信息。 | **潜在扩散模型 (Latent Diffusion Model)**：预测非自回归的连续潜在向量，替代了离散 Token 和自回归模型。 | **神经音频编解码器 (Neural Audio Codec Decoder)**：将扩散模型预测出的连续潜在向量重建为高质量的语音波形。 |
| **StyleTTS 2** | **声学文本编码器 + 韵律文本编码器**：使用预训练的 PL-BERT 提取强大的上下文韵律表征。 | **风格扩散模型 (Style Diffusion) + 可微时长建模**：用扩散模型采样出固定长度的“风格向量”，再结合可微上采样进行端到端联合训练。 | **HiFi-GAN 或 iSTFTNet 解码器**：去除了原本的梅尔频谱投影层，直接由风格向量和文本表征生成波形。 |

# VAE在端到端中的作用

### 目的一：充当“桥梁”，实现真正的端到端联合训练（End-to-End Training）

在传统的级联模型中，系统必须先生成中间声学特征（如梅尔频谱图），然后再把它交给声码器。这种硬性拼接容易导致误差累积（Error Propagation）。

- **代表模型：VITS、YourTTS、NaturalSpeech**
- **具体用法**：在 **VITS** 和基于它改进的 **YourTTS** 中，科学家们利用 VAE 将文本到语音的前端模块和声码器后端无缝“连接”了起来。VAE 的隐变量（Latent Variables）取代了固定的梅尔频谱图，成为了两者交流的“内部语言”。
- **收益**：这种设计允许整个系统（声学模型+声码器）在同一个损失函数下进行单阶段（Single-stage）的联合优化，彻底避免了前后模块之间的训练-推理不匹配（Training-inference mismatch）问题。

### 目的二：解决“一对多”映射难题，让声音更有感情和多样性（Expressiveness & Diversity）

一段同样的文字（如“你好”），人类可以用开心、生气、快或慢等无数种方式读出来，这就是 TTS 中著名的“一对多映射（One-to-many mapping）”难题。如果模型强行去记平均值，生成的声音就会极其平庸和机械（Over-smoothing）。

- **代表模型：NaturalSpeech、VITS 以及综述中提到的 VAE-TTS**
- **具体用法**：VAE 天生具备概率建模（Uncertainty modeling）的能力。在 **NaturalSpeech** 中，它被用来压缩语音中的各种复杂细节（如语调、重音）形成后验分布，再让文本特征去匹配这个分布。NaturalSpeech 甚至创新性地引入了“带记忆机制的 VAE（Memory based VAE）”来进一步简化这个过程。
- **收益**：在 **VITS** 和 **NaturalSpeech** 中，VAE 的介入使得模型能够捕捉并表达文本本身无法体现的语音变化（如音高和节奏），从而生成听起来如同真人般自然且富有表现力的声音。综述指出，这也是 VAE 框架常用于控制和解耦风格特征的原因。

### 目的三：作为“神经音频编解码器”，实现极端的数据压缩（Neural Audio Codec）

面对动辄几万采样率的物理声波，如果直接让语言模型或扩散模型去一帧帧预测，计算量会爆炸。

- **代表模型：VALL-E、NaturalSpeech 2**
- **具体用法**：在这两篇论文中，研究者提到了 VAE 的一种离散化变体——**VQ-VAE（向量量化变分自编码器）**。**NaturalSpeech 2** 提到，像 SoundStream 或 Encodec 这样的工具，正是利用了 VQ-VAE 以及残差向量量化技术，将极长、连续的原始语音波形，“压缩”成了非常短的离散 Token 序列或连续向量。在 **VALL-E** 的早期研究背景中，也利用 VQ-VAE 将未标注的语音离散化为 Token 序列来训练语言模型。
- **收益**：它极大缩短了数据长度，使得后续的自回归语言模型（如 VALL-E）或扩散模型（如 NaturalSpeech 2）能够高效地预测这些压缩后的“密码”，然后再用解码器将它们还原

成高保真波形。