YourTTS

1. title && abstract

- **解决的问题**：在训练中仅使用极少量目标语言或说话人数据的情况下，如何实现高质量的**零样本多说话人语音合成（ZS-TTS）与语音转换**。
- **核心方法**：在 **VITS 模型**的基础上，加入针对**零样本多说话人和多语言训练**的创新性修改（例如多语言方法）。
- **目标与贡献**：在 VCTK 数据集上实现了零样本多说话人 TTS 的 SOTA 结果，并在零样本语音转换上达到了与 SOTA 相当的水平。
  - 模型仅需不到 1 分钟的语音**微调**，即可在声音相似度上达到 SOTA 且保持合理的合成质量 。

2. intro

> **Question**
>
> 为什么需要 ZS-TTS?
>
> 1. 训练集中见过的，相似度好；没见过的，相似度差。
> 2. 要想训练一个好的 ZS-TTS 模型，需要收集大量不同说话人的录音 。SC-GlowTTS 尝试只用 11 个人来训练，结果发现严重阻碍了模型的泛化能力 。
> 3. 资源匮乏的低资源语言根本没有条件训练出高质量的 ZS-TTS 模型 。

- TTS已经相当成熟，但是TTS的结果是根据训练样本而定制的，需要 zero-shot 来扩展。
- **解决方法**：**Multilingual TTS** 中获得灵感—— 语码转化（code-switching）

3. method

- **VITS 架构**：结合了条件变分自编码器（Conditional VAE）和 对抗学习 的端到端 TTS 模型。

模型核心架构

YourTTS_architecture

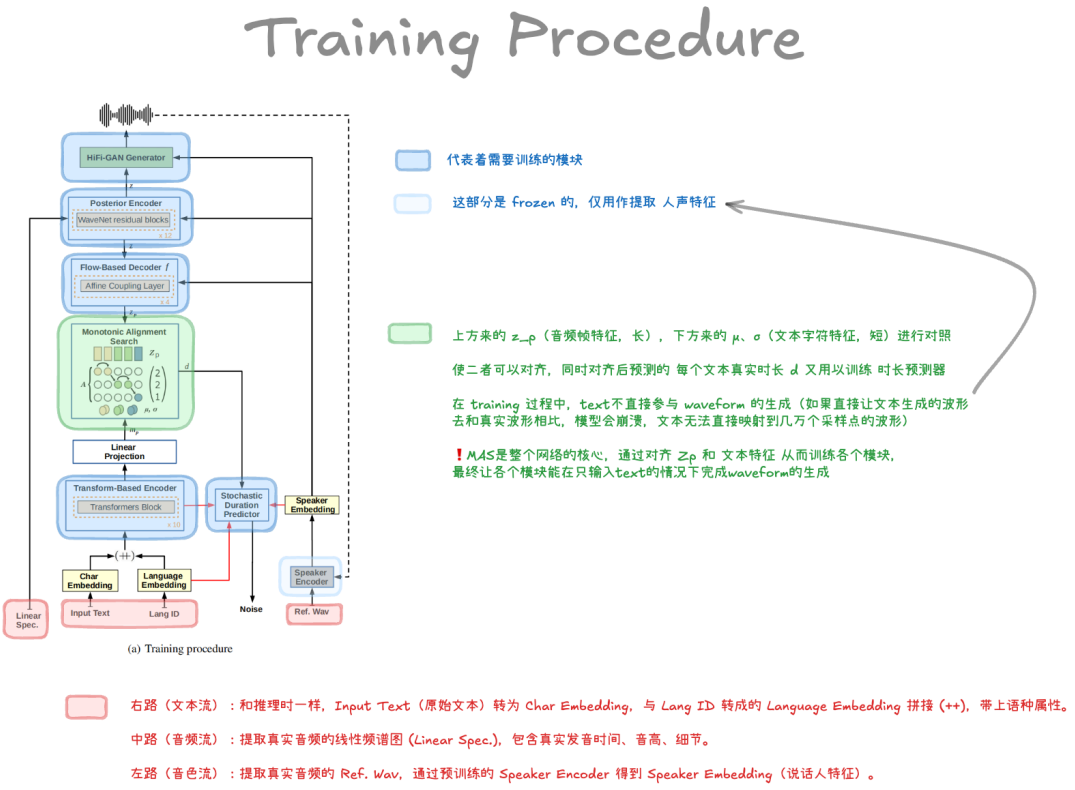

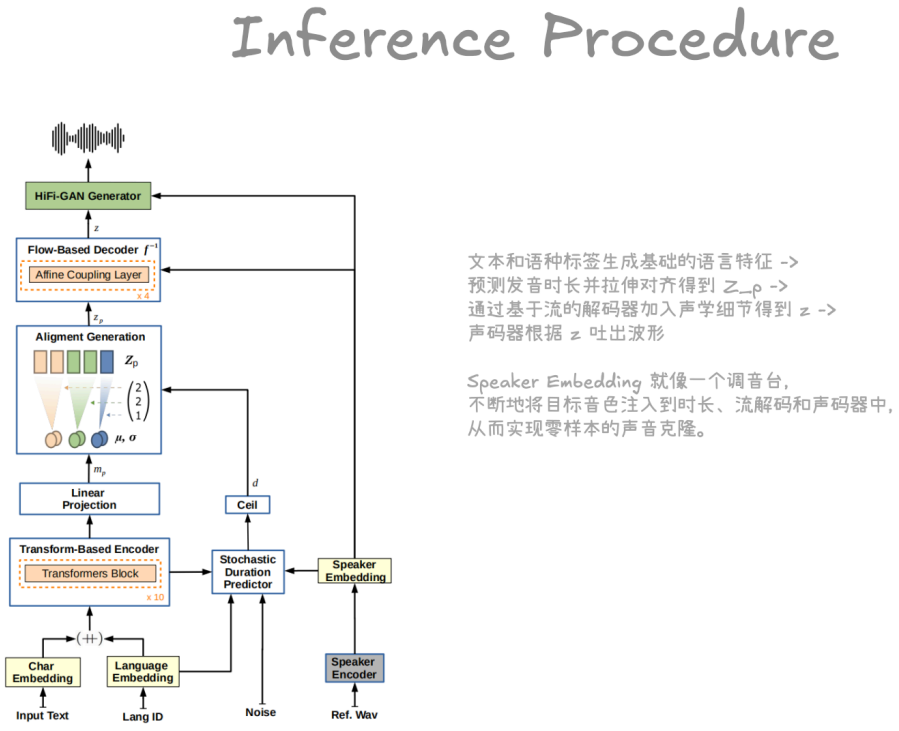

image-204.png

3.1. 其余技术细节：

全局条件注入（Global Conditioning）

- `Speaker Embedding` 提取出来后：**音色特征被同时注入了 4 个地方**：后验编码器、Flow 解码器、时长预测器、声码器。

- **为什么这么做**：这就是零样本（Zero-Shot）克隆成功的关键。它确保了在从特征压缩、对齐、预测节奏到最终生成波形的**每一个微小环节**中，目标说话人的音色标签都在发挥“控制”作用，防止模型在处理长语音时音色跑偏。

梯度截断（Stop-Gradient）

- 在 PyTorch 代码实现中，这里通常会加一个 `.detach()` 操作，切断反向传播的梯度。
- **物理意义**：时长预测器可以“看”文本特征来学习怎么断句，但是如果它学得不好，产生误差了，这个误差**绝对不允许**反向传导给文本编码器去修改文本特征。因为文本编码器的首要任务是理解“语义和发音”，不能被“节奏预测”的误差带偏。这是一种非常经典的模块解耦技巧。

语言嵌入（Language Embedding）

- **4维可训练嵌入 (4-dim Trainable Embedding)**：它是“可训练的”，意味着模型会根据训练数据自动调整这些数字，以最优化地代表该语言的特征。
  - ! YourTTS 为每一个语言准备了一个4维的 embedding ，如果 Lookup Table 有要推导的语种就能大大提高预测准确率；如果没有用类似的语种也比没有好。

3.2.Contributions

- **核心一：首个多语言零样本框架**：这是首个在零样本多说话人 TTS 领域提出并应用多语言（Multilingual）训练方法的工作 。它允许模型利用 A 语言的丰富说话人特征，来增强 B 语言的合成能力 。
- **核心二：低资源语种的突破**：即使在目标语言中只有一个说话人的数据集，该方法也能实现高质量的零样本多说话人合成与语音转换 。
- **核心三：极速声音自适应（Speaker Adaptation）**：模型仅需少于 1 分钟（最低甚至仅需 20 秒）的目标说话人语音进行微调，即可在声音相似度和质量上达到 SOTA 水平 。
- **核心设计一：多语言联合训练 (Multilingual Approach)**
  - **实现方式**：在 `Text Encoder`（文本编码器）阶段，将 **4 维可训练的语言嵌入（Language Embeddings）** 直接与每个输入字符的嵌入向量进行拼接（Concatenation） 。
  - **作用**：这让模型在处理文本时，能够感知不同语言的独特性。同时，模型在训练时采用了**语言均衡的采样策略（Language balanced batch）**，确保模型不会偏向某一种强势语言 。
    - ? 关于这个维度我还没太搞懂
- **核心设计二：低资源/单说话人克隆 (Zero-Shot Capability)**
  - **实现方式**：引入**全局条件（Global Conditioning）**。模型的所有关键组件（Flow-based decoder、Posterior encoder 和 Vocoder）都以**外部说话人嵌入（External Speaker Embeddings）** 作为输入条件 。

    - **作用**：通过解耦“内容（文本）”和“音色（说话人特征）”，模型学会了将从数据丰富的语言（如英语）中学到的说话人泛化能力，直接迁移到数据匮乏的语言（如葡萄牙语）上 。
- **核心设计三：极速声音自适应 (Speaker Adaptation)**
    - **实现方式**：引入**说话人一致性损失（Speaker Consistency Loss, SCL）** 。
    - **作用**：在微调阶段，模型利用预训练的说话人编码器来计算生成音频与原始音频的余弦相似度，并最大化这一相似度 。这种强约束使得模型仅需少于 1 分钟的数据就能快速捕获目标声音的独特性 。

4. experiment

5. conclusion

- **实验说明了什么**：在仅使用单说话人数据集的目标语言（如葡萄牙语）中，模型依然能展现出跨语种零样本生成潜力；同时，对于那些在训练中从未见过的、录音条件或音色差异巨大的说话人，模型可以通过少于 1 分钟的音频自适应其声音特征 。
- **局限性**：**随机时长预测器**存在不稳定性，且由于未使用音素转录（Phonetic transcriptions）直接使用原始文本，会导致发音错误 。由于训练数据中缺乏葡萄牙语女性声音，模型在处理该性别的语音转换时表现不佳 。