VITS

1. title && abstract

- VITS 的核心突破在于：不仅实现了高效的**端到端**并行生成，而且合成的语音在自然度上**超越了当前最好的两阶段模型**。
  - ℹ 传统两阶段痛点：训练繁琐、误差级联、中间特征的表达瓶颈
- **核心结构：** cVAE + FIOW + GAN

2. intro

写作思路：提出问题–分析问题–给出解决方案–总结贡献

> **Question1**
>
> **两阶段级联模型（Two-stage Pipeline）** 的问题?

三大致命缺陷：

1. **训练繁琐且次优**：两个模型通常需要独立训练，或者在一个阶段训练好之后再进行联合微调（Fine-tuning）。这种顺序训练无法实现全局最优。
2. **误差级联（Error Propagation）**：第一阶段预测的梅尔频谱如果存在微小误差，输入到第二阶段声码器时，误差会被放大，导致最终生成的音频出现伪影或不自然。
3. **中间特征的表达瓶颈**：梅尔频谱虽然是一种很好的声学特征，但它终究是人类预定义的。强制神经网络去学习这种特定的中间表示，反而可能限制了模型直接从文本学习丰富隐式语音特征的潜力。

> **Question2**
>
> **TTS中的“一对多”映射问题**

- **概念解析**：同一句文本，不同的人读、同一个人在不同情绪下读，其语调（Pitch）、节奏（Rhythm）、每个音素的发音时长（Duration）都是千变万化的。
- **现有方法的不足**：传统的非自回归模型（如 FastSpeech 系列）通常倾向于预测这些变化特征的“平均值”，导致生成的语音听起来平淡、机械，缺乏人类语音的起伏和情感表现力。

整个 TTS 过程构建为一个**条件变分自编码器（Conditional VAE）**

1. **端到端连接**：**潜在变量**直接连接了文本编码器（Text Encoder）和波形解码器（Waveform Decoder），彻底淘汰了梅尔频谱这一中间步骤，实现了真正的单阶段端到端训练。

2. **引入规范化流（Normalizing Flows）**：为了解决传统 VAE 生成结果模糊（在语音中表现为发音不清晰）的问题，作者在 VAE 的先验分布中引入了规范化流。这极大地提升了模型对复杂语音数据分布的建模和表达能力。
3. **结合对抗学习（Adversarial Learning）**：为了进一步逼近真实人类的声音质感，作者将 GAN（生成对抗网络）的判别器引入到波形解码阶段，迫使模型生成高保真度的音频。

- **随机时长预测器**：设计了一个**基于流的“随机时长预测器”**，用于从输入文本合成具有多样化节奏的语音。

> **Summary**
>
> - **史无前例的性能**：VITS 是**首个**在自然度上完全匹配甚至超越了经过精细微调的、最先进的两阶段级联模型（State-of-the-Art Two-stage models）的完全端到端 TTS 模型。
> - **架构创新**：证明了结合 VAE、规范化流和 GAN 进行单一框架联合训练的巨大潜力。

3. method

视频讲解

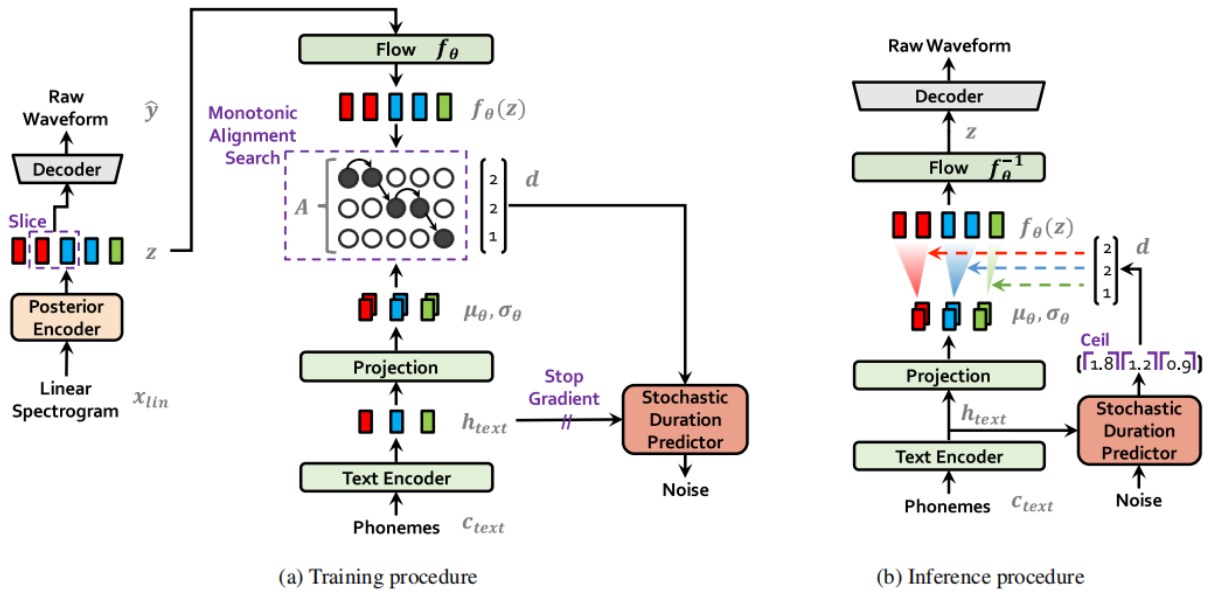

image-202.png

1. 核心目标：条件变分自编码器（VAE) 与 ELBO

VITS 的整体框架是一个条件变分自编码器 。它的核心优化目标是最大化数据的边缘对数似然 $\log p_\theta(x|c)$ 的变分下界（ELBO，Evidence Lower Bound）

公式 (1) 定义了这一目标：

$$\log p_\theta(x|c) \geq \mathbb{E}_{q_\phi(z|x)}\left[\log p_\theta(x|z) - \log \frac{q_\phi(z|x)}{p_\theta(z|c)}\right]$$

2. 重构损失

预测结束后VITS 并没有直接在原始波形域计算 VAE 的重构损失，而是将其转换到了梅尔频谱域 （更符合人耳听觉）。

公式 (2) 定义了重构损失：

$$L_{recon} = ||x_{mel} - \hat{x}_{mel}||_1$$

- x_{mel} 是真实波形提取的梅尔频谱 。
- $\hat{x}_{mel}$ 是潜在变量 z 经过解码器（生成波形 $\hat{y}$）再经过 STFT 提取出的预测梅尔频谱 。

3. KL 散度与规范化流

为了让后验编码器获得更高分辨率的输入，模型输入使用了线性频谱 x_{lin} 。同时，为了增强先验分布的表达能力，使其不再局限于简单的正态分布，VITS 在先验网络上叠加了**规范化流（Normalizing Flow, f_θ）** 。

KL 散度的计算变为公式 (3)：

$$L_{kl} = \log q_\phi(z|x_{lin}) - \log p_\theta(z|c_{text}, A)$$

其中，应用规范化流后基于变量代换（Change-of-variables）定理的先验分布如公式 (4) 所示：

$$p_\theta(z|c) = \mathcal{N}(f_\theta(z); \mu_\theta(c), \sigma_\theta(c)) \left|\det \frac{\partial f_\theta(z)}{\partial z}\right|$$

- 传统的 VAE 假设先验服从标准正态分布，这导致生成结果模糊（过度平滑）。引入 f_θ 后，模型能够将简单的正态分布映射为高度复杂的语音隐变量分布 。
- 这里的条件 $c = [c_{text}, A]$，意味着先验分布不仅受文本影响，还受到文本与语音对齐方式 A 的严格约束 。

4. 寻找对齐矩阵：单调对齐搜索 (MAS)

由于文本和语音之间不存在真实的对齐标签，模型必须在每次训练迭代中自行寻找最优对齐矩阵 A 。VITS 修改了 Glow-TTS 中的 MAS 算法，使其目标转为最大化 ELBO 。

公式 (6) 展示了对齐搜索的目标：

$$\hat{A} = \arg\max_A \log p_\theta(x_{mel}|z) - \log \frac{q_\phi(z|x_{lin})}{p_\theta(z|c_{text}, \hat{A})} = \arg\max_A \log p_\theta(z|c_{text}, \hat{A})$$

$$= \log \mathcal{N}(f_\theta(z); \mu_\theta(c_{text}, \hat{A}), \sigma_\theta(c_{text}, \hat{A}))$$

- 因为重构项和后验项与 A 无关，最大化 ELBO 实际上等价于寻找一个 A，使得当前潜在变量 z 在文本先验条件下的对数似然最大化 。
- 这本质上是一个动态规划问题，通过限制对齐是单调且不跳步的（模拟人类阅读习惯）来求解最优路径 。

5. 随机时长预测器 (Stochastic Duration Predictor) 的变分下界

❓ 这里没太懂？这个不是根据 MAS 对齐来训练吗？

解决了一对多的节奏变化问题，是 VITS 的一大亮点。音素时长是一个离散的标量（整数），这导致无法直接使用连续的流模型（Flow-based model）进行最大似然估计 。因此，论文引入了变分反量化（Variational Dequantization，u）和变分数据增强（Variational Data Augmentation，ν） 。

公式 (7) 定义了时长的变分下界：

$$\log p_\theta(d|c_{text}) \geq \mathbb{E}_{q_\phi(u,\nu|d,c_{text})}\left[\log \frac{p_\theta(d-u,\nu|c_{text})}{q_\phi(u,\nu|d,c_{text})}\right]$$

6. 波形域对抗训练 (Adversarial Training)

❓ 这里没太懂?

为了消除声学模型和声码器级联带来的伪影，并直接生成高保真波形，VITS 在解码器（此时充当生成器 G）后接了一个判别器 D 。

使用了最小二乘 GAN 损失（公式 8, 9）和特征匹配损失（公式 10）：

$$L_{adv}(D) = \mathbb{E}_{(y,z)}[(D(y)-1)^2 + (D(G(z)))^2]$$

$$L_{adv}(G) = \mathbb{E}_z[(D(G(z))-1)^2]$$

$$L_{fm}(G) = \mathbb{E}_{(y,z)}\left[\sum_{l=1}^{T}\frac{1}{N_l}||D^l(y)-D^l(G(z))||_1\right]$$

7. 终极一统：总损失函数

将上述所有推导模块组合，得到了 VITS 端到端训练的最终损失函数公式 (11)：

$$L_{vae} = L_{recon} + L_{kl} + L_{dur} + L_{adv}(G) + L_{fm}(G)$$

总损失 L_{vae} 完美融合了变分推断（负责对齐与隐特征学习）、对抗学习（负责音频高频细节）和随机时长预测（负责节奏多样性） 。

训练与推导过程核心差异

阶段 / 模块	(a) 训练过程 (Training Procedure)	(b) 推导过程 (Inference Procedure)	核心差异说明
输入数据 (Inputs)	文本音素 (c_{text}) + **真实音频频谱** (x_{lin})	仅文本音素 (c_{text}) + 随机噪声	训练时需要音频来学习目标特征；推导时模型必须“无中生有”，仅靠文本生成音频。
隐变量 z 的来源	由**后验编码器**从真实的音频频谱中提取得出。	z 是由文本特征经过扩展、对齐后，通过 **逆向 Flow (f_θ^{-1})** 采样计算得出的。	训练时 z 包含真实的声学细节；推导时 z 是模型基于文本“想象”出来的。
对齐机制 (Alignment & Duration)	使用 **单调对齐搜索 (MAS)**。它通过对比音频特征和文本特征，强行找出当前音频中每个音素发音的“真实持续时间”。	使用 **随机时长预测器**预测并进行向上取整 (`Ceil`) 处理。	训练时是**寻找/提取**真实时长作为标答；推导时是**预测**时长来控制生成节奏。
时长预测器的作用	接收文本特征并尝试预测 MAS 给出的“真实时长”，通过计算 Loss 来更新参数。	输出预测的时长数组，将短促的文本特征向量按此时长**复制拉长**。	训练时为了学习；推导时用于实际扩展文本序列以匹配音频帧数。
归一化流 (Flow)	**正向 Flow (f_θ)**：试图将复杂的音频隐变量 z 映射为一个简单分布，去逼近文本特征的先验分布。	**逆向 Flow (f_θ^{-1})**：将扩展后的简单文本特征分布，映射回复杂的、包含丰富声学细节的隐变量 z。	Flow 模块具有可逆性，训练走正向压平分布，推导走逆向生成复杂特征。
解码器输入 (Decoder)	通常为了节省显存，只取 z 的一个**切片 (Slice)** 喂给解码器重建波形。	将完整的、生成的序列 z 全部喂给解码器。	推导时需要合成完整的长语音，不能只切片。

4. experiment

5. conclusion

- 对上文总结..

🚀 帮助理解版本：

VAE（变分自编码器）—— 隐形的连接桥梁 在传统的系统中，文字和音频是被强行切成两段的。而在 VITS 中，VAE 的作用就像是建了一座桥。它通过一种叫做“隐变量”（latent variables）的神秘物质，**将文本处理和音频生成首尾相连，实现了高效的端到端学习**。因为不

再需要显式地生成固定的“梅尔频谱图”做中转，所以彻底斩断了传统模型中“中间特征误差叠加”的烦恼。

标准化流（Normalizing Flows）—— 表达力放大器 声音是非常复杂多变的。为了让生成的语音拥有像真人一样丰富的细节，VITS 在它的模型内部（具体来说是条件先验分布上）加入了标准化流。你可以把它想象成一个极具弹性的“变形器”，它**能够遵循数学上的变量替换法则，将一个简单、死板的概率分布，转换成一个极度复杂且能表达丰富人类声音特征的分布**。这就大大提升了模型生成逼真样本的能力。

GAN（生成对抗网络）—— 严苛的“黄金质检员” 光有前面两个还不够，为了让最终输出的音频波形达到极致的高保真度，VITS 在波形生成阶段引入了对抗训练。系统中设置了一个名为“判别器”（Discriminator）的角色，**它的唯一工作就是像个极其挑剔的质检员一样，去分辨这段音频到底是机器生成的，还是真人录的真实波形**。在这场“猫鼠游戏”中，负责生成声音的“生成器”为了骗过判别器，就会被逼着生成越来越接近真人音质的高质量声音。

单调对齐搜索MAS：在不跳跃发声的情况下，模型自动寻找文本和声音特征之间最为匹配的排列组合
随机时长预测器：设计了一个**基于流的“随机时长预测器”**，用于从输入文本合成具有多样化节奏的语音。