Tacotron

Contributions

1. 真正的端到端联合优化范式，无需进行冗余的模块设计。
2. Attention自动对齐：让神经网络自己去摸索文本和音频之间在时间轴上的对应关系。
3. 一次预测 r 个 frames，加快速度

1. title && abstract

- 本文提出了一种名为 Tacotron 的端到端生成式文本转语音（TTS）模型，该模型能够直接将字符序列合成为语音信号 。
  - 端到端指：一个系统或模型能够直接从原始输入数据（一端）映射到最终输出结果（另一端），省略中间步骤。
- 给定 `<文本，音频>` 数据对，该模型可以完全从零开始随机初始化训练 。
- 评分高
- 由于其在帧级别（frame level）生成语音，因此比样本级别的自回归方法速度更快 。

2. intro

Q1

为什么要端到端?

- **传统流程（流水线 Pipeline）：** 传统的文本转语音合成系统通常由多个阶段组成，例如文本分析前端、声学模型和音频合成模块。(繁琐)
- **端到端流程（如 Tacotron）：** 端到端生成式文本转语音模型可以直接从字符生成语音 。只要提供 `<文本，音频>` 数据对，模型就可以完全从零开始、在随机初始化的状态下进行训练，无需显式地提取中间语言学特征。
- 端到端模型使得在模型初期即可加入**说话人、语言或情感等丰富的条件特征** 。

Q1

为什么以前不用端到端?

- **核心困难：** TTS 本质上是一个大规模的逆问题。
  1. **信号层面的巨大变异性**：同一段文本可以对应完全不同的发音方式或说话风格 。

2. **输出数据的连续性**
3. **输入输出序列长度极度不对等**：TTS 的输出序列（音频帧或采样点）通常远远长于其输入序列（字符或音素）
4. **极易引发误差累积**：由于输出是连续且漫长的序列，在自回归或按步生成的过程中，预测误差会极其快速地累积。

总结而言，就是文本信息含义是复杂的，但是放到音频中就必须表达出来，有如上四点问题， Tacotron 就是用以解决这些问题。

- **解决**：该模型巧妙地引入了基于注意力机制的序列到序列（seq2seq with attention）范式，以此作为一个端到端的生成式 TTS 框架来应对这一挑战。

3. method

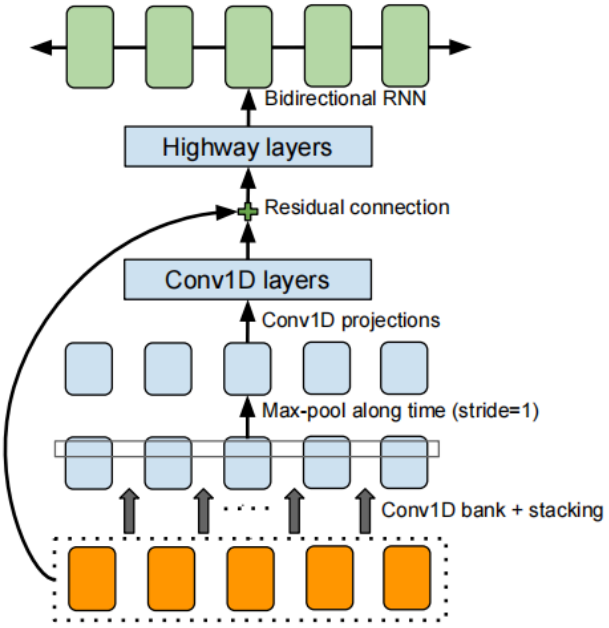

Figure 2: The CBHG (1-D convolution bank + highway network + bidirectional GRU) module adapted from Lee et al. (2016).

image-181.png

- **CBHG**：**C**onv1D bank（一维卷积组） + **H**ighway network（高速网络） + bidirectional **G**RU（双向门控循环单元）

  早期的 attention层?

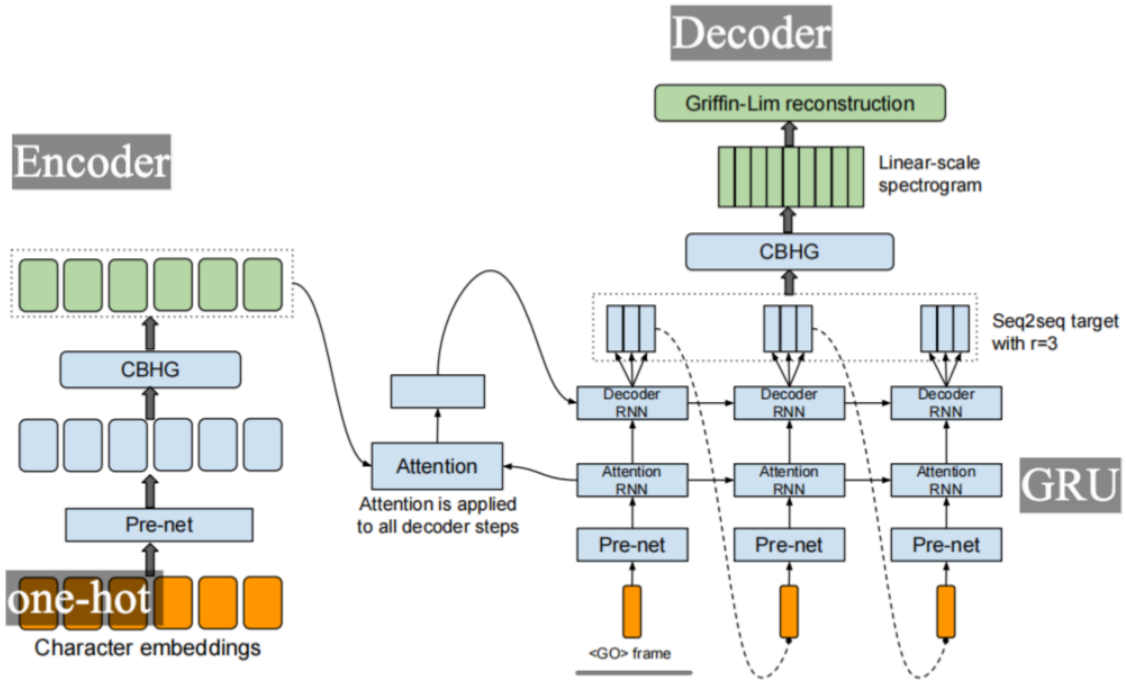

image-180.png

input&&output

characters → spectrogram frames → waveforms

- **一次预测多个 frames：** 如果一次只发射一帧，会迫使注意力机制在多个时间步内停留在同一个输入字符上；而一次发射多个帧，允许注意力机制在训练早期就尽早向前推进 。

encoder

1. 输入文本经过nn.embeding映射为词向量
2. prenet (三层DNN+Relu+Dropout，增加非线性，帮助收敛，提高泛化性)
3. CBHG结构（降低过拟合，减少合成错误）

decoder

- 上一步帧输入 → Pre-net → **Attention RNN** → *(产生Query)* → **Attention模块算出上下文向量** → *(将上下文向量与Attention RNN输出拼接)* → **Decoder RNNs** → 预测出 r 帧梅尔频谱图

! Tacotron 里的 Attention 解决了 **“空间（信息容量）上的遗忘”**，但因为它依附于 RNN 这个必须按时间顺序运行的底座，所以它**无法摆脱串行枷锁**。

4. experiment

5. conclusion

- Tacotron 证明了无需手工设计的语言特征或复杂的隐马尔可夫模型（HMM）对齐器，端到端 TTS 也是可行的 。

- 该系统通过简单的波形合成模块（Griffin-Lim）实现了高质量的语音输出 。
- 作者也客观地指出了现有研究的局限性，例如 Griffin-Lim 算法会产生可听见的伪影，并提出未来将致力于开发快速、高质量的基于神经网络的频谱图逆变换方法 。