WaveNet

Contributions

a) 一句话核心思想：**按时间顺序直接写出声音。**
b) 速记版 Pipeline
1. 把声音切成一个个采样点。
2. 每次只看前面的点，预测下一个点。
3. 用空洞卷积把“能看到的历史”拉长。
4. 加入文本、说话人或 F0 条件，控制输出声音。
5. 重复采样，直到整段音频生成完(自回归)。

0. 摘要

- 本文提出了一种名为 WaveNet 的深度神经网络，专门用于生成原始音频波形 。
- 该模型具有完全的概率性和自回归特性，每个音频样本的预测分布都以前面所有的样本为条件。
  - **核心理念**：一种专门用于处理和生成“序列数据”的模型。它的本质逻辑是：**利用变量自己过去的历史序列，来预测它未来的下一个状态。**
- 评价好：WaveNet 在文本转语音（TTS）任务中达到了业界最先进的性能。
- 用途广泛：单一模型能够捕捉多个说话者的特征，能够生成新颖的音乐片段，并可在语音识别等判别性任务中返回极具潜力的结果 。

1. 方法动机

- a) 提出动机：之前的工作基于**串接式TTS**技术，传统语音生成大多先预测**声码器参数**，再用 **vocoder** 重建波形。
  - 这条链路里会引入**强先验、平滑效应和细节损失**，最终让语音听起来“糊”“假”“有机械感”。
  - 波形生成，可以不靠传统 vocoder，而直接让神经网络建模 raw waveform, 且这种方法能让自然度显著提高。
- b) 现有方法痛点：论文在附录里明确批评了三类传统假设：固定窗长分析、线性滤波假设、Gaussian process 假设。这些假设对真实语音过强，难以表达瞬态、非线性和非高斯细节。
- c) 核心假设与直觉：如果直接在原始波形层面建模，一次处理一个样本，并把“下一个采样点”写成对“前面所有采样点”的条件分布，那么模型就能自己学到细粒度声学结构。
  - 这种架构能否成功生成具有极高时间分辨率（至少 16,000 样本/秒）的宽带原始音频波形。

> 理论前提：
> However, our PixelRNN and PixelCNN models, published earlier this year, showed that it was possible to generate complex natural images not only one pixel at a time, but one colour-channel at a time, requiring thousands of predictions per image. This inspired us to adapt our two-dimensional PixelNets to a one-dimensional WaveNet.

2. 方法设计

第一步：确立核心生成逻辑 —— 自回归概率模型

这意味着我们要把一段包含 T 个采样点的完整音频波形 $x = \{x_1, \ldots, x_T\}$ 的生成问题，转化为一个严格依赖历史信息的条件概率序列。

根据概率论的链式法则，波形的联合概率被分解为条件概率的乘积：

$$p(x) = \prod_{t=1}^{T} p(x_t | x_1, \ldots, x_{t-1})$$

- 在时刻 t 生成的音频样本 x_t，必须且只能以前面所有已经生成的样本 $(x_1, \ldots, x_{t-1})$ 为条件，不能查看后续的样本。

第二步：输出维度的降维与量化 —— μ-law 压扩与 Softmax

由于原始音频通常以 16 位整数存储，如果直接预测，模型在每一个时间步都需要输出一个包含 65,536 个概率值的分布，这在计算上极其昂贵 。

模型首先应用 μ-law 压扩变换（Companding Transformation）将音频数据压缩，然后量化为 256 个可能的值：

$$f(x_t) = sign(x_t) \frac{ln(1 + \mu |x_t|)}{ln(1 + \mu)}$$

其中，$\mu = 255$ 且 $-1 < x_t < 1$ 。

预测出结果 y_t 后（这里 y_t 是将 0-255 映射回 -1 到 1 之间的值），系统需要套用其**逆函数（Inverse μ-law expansion）** 来进行还原：

$$x_t = sign(y_t) \frac{(1 + \mu)^{|y_t|} - 1}{\mu}$$

- 这种非线性量化比简单的线性量化能保留更多的声音细节（尤其是人声），同时大大降低了计算复杂度 。

第三步：打破时序记忆瓶颈 —— 空洞因果卷积

模型采用了**因果卷积（Causal Convolutions）**，通过对卷积输出进行时间偏移，确保 t 时刻的预测只依赖 t 及之前的输入 。

1s有16000个样本点，为减少计算，WaveNet 引入了核心创新：**空洞卷积（Dilated Convolutions）** 。

空洞卷积通过在卷积核的值之间“跳步”（填充零）来跨越更长的时间范围 。WaveNet 按照指数级增加空洞因子，例如按周期堆叠：$1, 2, 4, \ldots, 512, 1, 2, 4, \ldots, 512$ 。

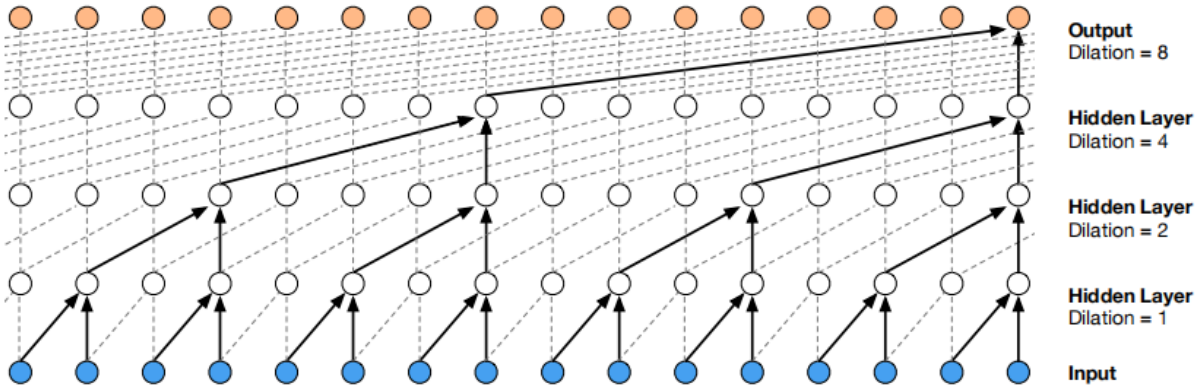

Figure 3: Visualization of a stack of *dilated* causal convolutional layers.

1 2 4 8 空洞卷积

? 这样不会丢失信息吗?

! 扩张因子，指数级增长使得仅用少数几层网络快速提高感受野，解决了预测波形具有极高分配率的问题

第四步：非线性特征提取 —— 门控激活单元与残差连接

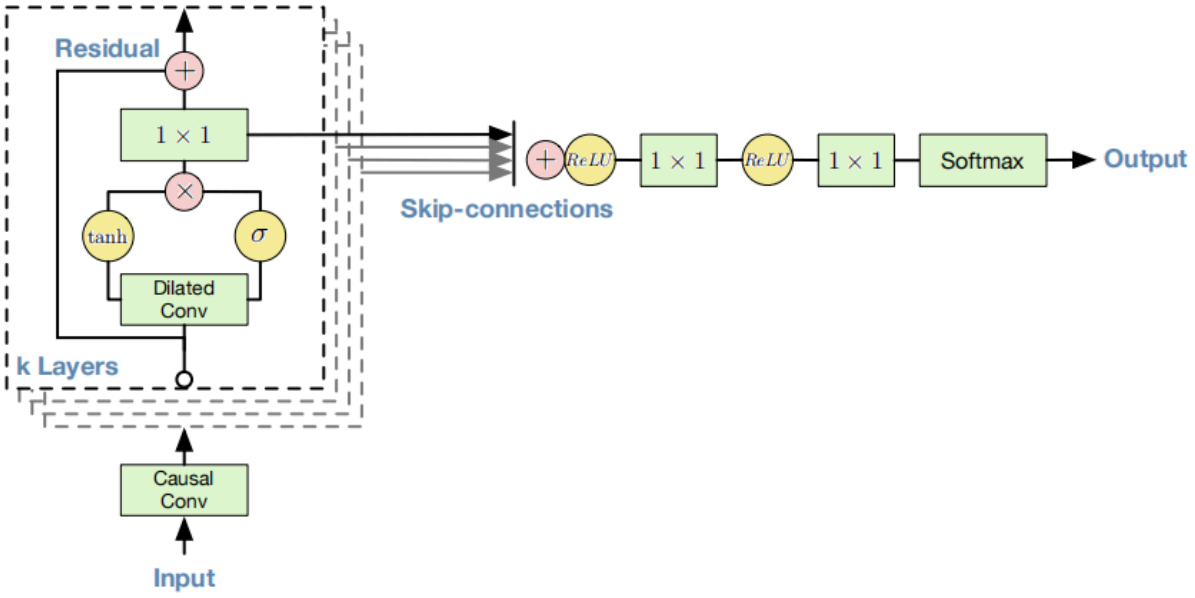

Figure 4: Overview of the residual block and the entire architecture.

第五步：条件生成机制

仅仅生成随机声音是不够的（比如 TTS 需要根据文本发音）。WaveNet 通过引入额外输入 h 或 y，将无条件分布 $p(x)$ 变成了条件分布 $p(x|h)$ 。

1. 全局条件化（Global Conditioning）： 例如输入某个特定的“说话人身份特征向量 h”，它会在所有时间步上全局影响生成的声音特征 。激活函数修改为：

$$z = \tanh(W_{f,k} * x + V_{f,k}^T h) \odot \sigma(W_{g,k} * x + V_{g,k}^T h)$$

这里通过可学习的线性映射 $V_{*,k}$ 将特征 h 注入到每一层的滤波器和门控中 。

2. 局部条件化（Local Conditioning）： 例如输入 TTS 的“语言学特征序列（如音素）h_t”。因为文本特征的采样率远低于音频（比如每秒只有几十个音素，但有 16000 个音频采样点），必须先通过转置卷积网络将其**上采样（Upsampling）**成与音频相同分辨率的序列 $y = f(h)$ 。激活函数修改为：

$$z = \tanh(W_{f,k} * x + V_{f,k} * y) \odot \sigma(W_{g,k} * x + V_{g,k} * y)$$

此时 $V_{*,k} * y$ 充当的是 1×1 卷积，在时间维度上精确制导每个时刻该发什么音 。

3. 与其他方法对比

a) 本质区别：WaveNet 直接建模**波形本身**，而不是先压成声码器参数再重建。
b) 创新点

1. 用空洞因果卷积解决原始音频的长时依赖问题。
2. 在波形层面使用离散 softmax 建模，而不是高斯混合之类的连续分布。
3. 统一了无条件生成、条件 TTS、多说话人建模、音乐生成和判别式识别。
4. 在 TTS 上显著缩小了合成语音与自然语音的主观差距。

c) 对比表格

方法	核心思路	优点	缺点	改进点
WaveNet	直接对原始波形做自回归建模	细节保真高，可做条件控制	逐点采样慢，长程一致性仍有限	用空洞卷积、门控、残差跳连提升建模能力
统计参数语音合成	预测 vocoder 参数后再重建波形	稳定、可控、较省资源	vocoder 失真、过平滑、自然度受限	绕过 vocoder，直接生成波形

方法	核心思路	优点	缺点	改进点
拼接式语音合成	从数据库中选取并拼接语音单元	某些场景自然度高	数据依赖强，灵活性差，多说话人扩展麻烦	用统一神经生成模型替代拼接

4. 实验表现

a) 实验设计：
多说话人生成用 VCTK，`44` 小时、`109` 位说话人；TTS 用 Google 英语 `24.6h` 和中文 `34.8h` 单说话人数据；音乐用 MagnaTagATune `~200h`、YouTube piano `~60h`；识别用 TIMIT。TTS 基线是 HMM-driven concatenative 和 LSTM-RNN statistical parametric。

> **Hint**
>
> 如果我们在没有文本序列的情况下训练该网络，它仍然会生成语音，但此时它必须自行编造内容——导致一种咿呀学语般的结果，其中真实的单词与编造的类似单词的音节交织在一起。
> 为了确保它能根据特定语句选择合适的发声者，我们根据说话者的身份对网络进行了条件训练。与仅针对某一位说话者进行训练相比，使用多位说话者进行训练反而能更好地建模该说话者的声音，这表明存在某种形式的**迁移学习**。

b) 关键结果：
TTS 的 MOS 显著提高。

系统	美式英语 MOS	中文 MOS
LSTM-RNN parametric	3.67	3.79
HMM concatenative	3.86	3.47
WaveNet (L+F)	**4.21**	**4.08**
Natural 8-bit μ-law	4.46	4.25
Natural 16-bit PCM	4.55	4.21

WaveNet 把“最佳合成语音”到“自然语音”的差距，从英语 `0.69` 降到 `0.34`，中文从 `0.42` 降到 `0.13`。此外，TIMIT 上达到 `18.8 PER`，作者称这是当时直接在原始音频上训练模型的最好结果。

c) 优势场景：
在主观自然度要求极高的 TTS 上优势最明显。多说话人实验也说明它能在一个模型里共享跨说话人的内部表示。音乐实验说明它能生成局部很像真的片段，但长程结构还不够稳。

d) 局限性：

论文自己已经暴露了几个问题。

第一，感受野虽然比普通卷积大很多，但对韵律、F0 这种长时依赖仍不够，导致只用 linguistic features 时会出现重音不自然。

第二，无文本约束的自由生成只能记住最近 `2–3` 个音素，长距离一致性不足。

第三，音乐生成即使感受野扩到几秒，仍会出现风格、音色、响度随时间漂移。

第四，逐点生成天生串行，推理速度不会轻松。

> ! 当波形生成足够强后，领域焦点开始前移，大家开始更关心：对齐、韵律、风格、可控性、多说话人、零样本克隆。