A Survey on Neural Speech Synthesis

全景图

- **tts 分步流程图**

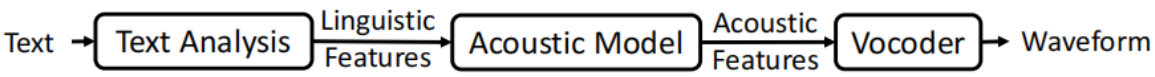

Figure 1: The three key components in neural TTS.

image-182.png

- **tts各部分组件典例**

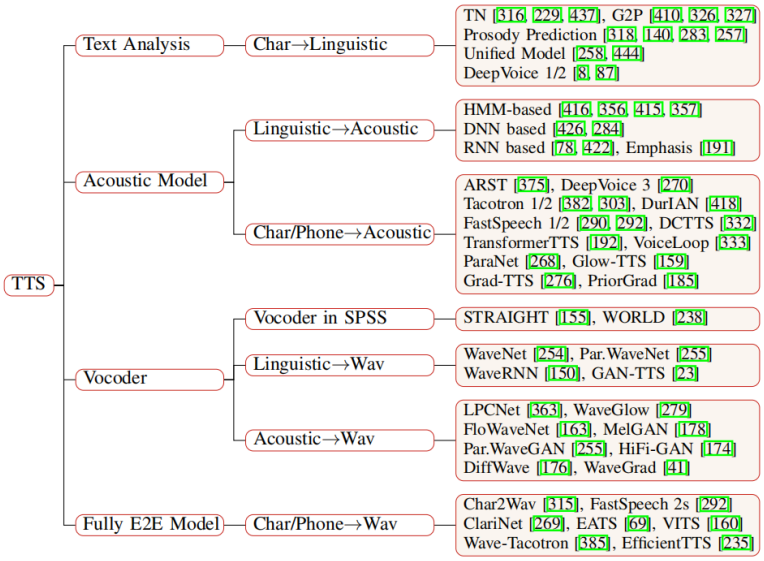

(a) A taxonomy of neural TTS.

image-183.png

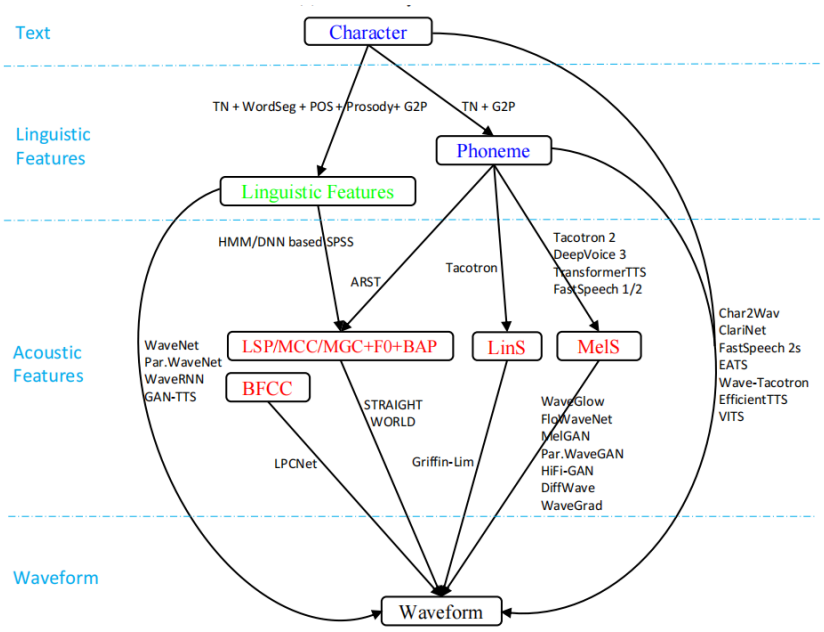

(b) The data flows from text to waveform.

Figure 3: A taxonomy of neural TTS from the perspectives of key components and data flows.

Text Analysis

主要有以下五个核心模块

1. 文本归一化（Text Normalization）

- **作用**：原始文本里经常有非标准词，计算机不知道怎么读，必须先转化为“口语形式的词汇”。
- **举例**：比如年份“1989”需要被转化为“一九八九”或“nineteen eighty nine”

2. 分词（Word Segmentation）

- **作用**：找出词与词之间的边界。这对像中文这种字符之间没有空格的语言尤为重要。
- **意义**：只有准确切分出词语，后续的词性标注、读音预测和停顿预测才能准确。

3. 词性标注（POS Tagging）

- **作用**：给每个词打上标签，比如标出它是名词、动词还是介词。
- **意义**：词性往往决定了一个词在句子里的发音轻重以及多音字的读音（比如“长”作形容词和动词时读音不同）。

4. 韵律预测（Prosody Prediction）

- **作用**：决定说话的节奏、重音和语调（涉及到音节的时长、响度和音高的变化）。
- **机制**：英文中常用 ToBI（Tones and Break Indices）系统来标注声调和停顿强度；而在中文语音合成中，通常会构建一个三层级的韵律树，包括：韵律词（PW）、韵律短语（PPH）和语调短语（IPH）。这就好比在播音员的稿子上画上停顿和情感起伏的记号。

5. 字音转换（Grapheme-to-Phoneme, 简称 G2P）

- **作用**：把文字符号转化为实际的读音（音素）。
- **核心挑战**：必须根据上下文，决定这个字到底读什么。
  - ! 现在的系统往往只保留“文本归一化”和“字音转换（G2P）”来获取最基础的读音像分词、词性和部分韵律信息，现代模型更倾向于通过海量数据自己去提取特征

Acoustic Model

1. 早期阶段：SPSS（统计参数）时代的声学模型

- **它是怎么工作的**：早期的模型（基于HMM、DNN或LSTM）接收文本分析送来的复杂语言特征，预测出一些低维的物理参数（比如基频、能量等）。
- **最大的痛点**：早期模型生成的参数总是存在 **“过平滑”（Over-smoothing）** 的问题。

- 反映在声音上，就是听起来发闷、缺乏细节、没有真人那种丰富的起伏和质感。

2. 现代阶段：端到端神经网络（Neural TTS）时代的崛起

- **端到端神经合成（End-to-End Neural TTS）阶段**：
  - **代表模型一：RNN架构（如Tacotron 1/2）**
    - **机制**：采用“编码器-注意力-解码器”框架，属于**自回归（Autoregressive, AR）**生成模型，即逐帧预测声学特征。
    - **痛点**：① 推理速度慢；② 注意力机制在对齐长文本与长语音时容易出错，导致严重的**漏读（Word skipping）** 或 **重复读（Word repeating）** 等鲁棒性问题。
      - ⚠ 这里的 attention 是用来对齐 encoder-decoder 的。
  - **代表模型二：CNN架构（如DeepVoice 3）**
    - **机制**：采用全卷积序列到序列模型直接预测梅尔频谱图，相较于RNN提升了部分并行能力。
  - **代表模型三：Transformer与并行架构（如FastSpeech 1/2）**
    - **机制**：采用 **非自回归（Non-autoregressive, NAR）** 架构。
    - **核心创新**：抛弃了传统的注意力机制，引入 **“时长预测器”（Duration Predictor / Length Regulator）** 来显式解决文本与语音的长度不匹配问题。
    - **优势**：推理速度极快（FastSpeech在频谱生成上提速达270倍），且由于解除了对注意力机制的依赖，彻底消除了漏读和结巴的问题。

> **Hint**
>
> **其他生成式模型**：近年来，Flow（流模型）、GAN（生成对抗网络）、VAE（变分自编码器）以及Diffusion（扩散模型）等高级生成模型也被广泛应用于声学特征的生成，以进一步提升语音的多样性和自然度。

Vocoder

1. 早期传统声码器（SPSS时代）

- **机制**：通过一套复杂的数学规则和声学先验知识，从频谱、基频（F0）等参数中计算出波形。
- **局限**：合成的声音往往带有明显的“机器味”或电子噪音。

2. 现代神经声码器（Neural Vocoders）

- **自回归模型（Autoregressive, AR Vocoders）**
  - **代表作**：WaveNet、WaveRNN、LPCNet。

- **机制**：几乎不依赖人类的声学先验知识，纯靠神经网络点对点地预测波形。
- **特点**：数学逻辑简单，生成的声音极其真实；但致命缺点是**无法并行计算**，生成速度极慢。为了提速，LPCNet 引入了传统的线性预测技术结合轻量级 RNN，大幅提高了运算效率。

- **流模型（Flow-based Vocoders）**
  - **代表作**：Parallel WaveNet、WaveGlow、FloWaveNet。
  - **机制**：通过一系列可逆变换，将标准概率分布（如高斯分布）映射为复杂的语音波形分布。
  - **特点**：支持并行生成，速度快。其中 WaveGlow 等模型结构简单且推理快，但代价是需要庞大的参数量来保证模型能力。
- **生成对抗网络（GAN-based Vocoders）**
  - **代表作**：MelGAN、Parallel WaveGAN、HiFi-GAN。
  - **机制**：包含一个生成器（负责将频谱图变波形）和一个判别器（负责鉴别生成的波形像不像真人发音）。许多先进模型引入了多尺度（Multi-scale）或多周期（Multi-period）的判别器，来捕捉声音在不同频率下的特征。
  - **特点**：能够实现非自回归的并行生成，推理速度极快，且音频保真度极高。
- **扩散模型（Diffusion-based Vocoders）**
  - **代表作**：DiffWave、WaveGrad。
  - **机制**：通过给音频不断加噪（扩散），然后再一步步去噪还原出目标语音。
  - **特点**：声音质量极高，但由于去噪过程需要多次迭代，推理速度通常较慢。

展示向完全端到端演化的过程

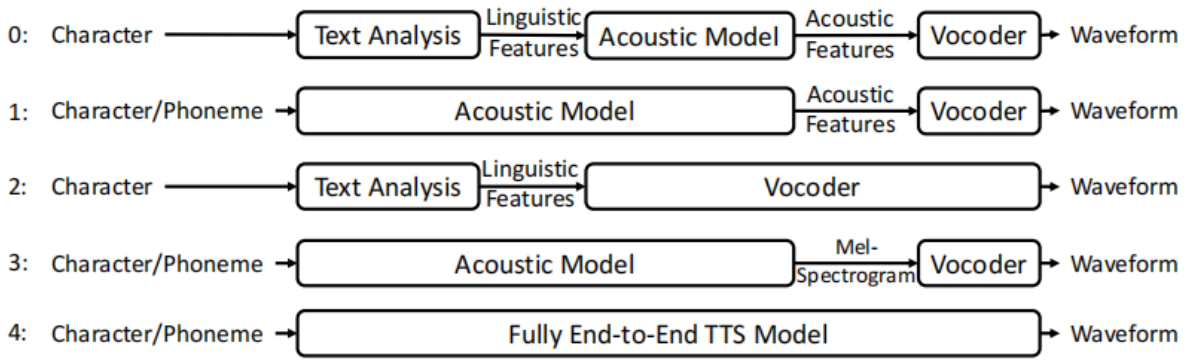

Stage	Models
0	SPSS [416, 356, 415, 425, 357]
1	ARST [375]
2	WaveNet [254], DeepVoice 1/2 [8, 87], Par. WaveNet [255], WaveRNN [150], HiFi-GAN [23]
3	DeepVoice 3 [270], Tacotron 2 [303], FastSpeech 1/2 [290, 292], WaveGlow [279], FloWaveNet [163]
4	Char2Wav [315], ClariNet [269], FastSpeech 2s [292], EATS [69], Wave-Tacotron [385], VITS [160]

Figure 4: The progressively end-to-end process for TTS models.

image-185.png

TTS五大方向

（待后续读论文补充）

1. 极速合成（Fast TTS）

- **核心痛点**：传统的自回归（AR）模型（如 Tacotron、WaveNet）在生成长序列语音时推理速度极慢（时间复杂度为 O(N)），且难以在算力受限的边缘设备（如手机、IoT设备）上部署。
- **主流解法**：
  - **非自回归（NAR）并行生成**：如 FastSpeech 1/2、Parallel WaveNet，将推理时间复杂度降至 O(1)。
  - **轻量化模型设计（Lightweight Model）**：利用网络修剪、量化、知识蒸馏或神经架构搜索（NAS，如 LightSpeech）来压缩模型体积。
  - **引入声学领域知识**：如 LPCNet，将传统的线性预测编码（LPC）数字信号处理技术与轻量级 RNN 结合，大幅降低计算复杂度。

2. 低资源合成（Low-Resource TTS）

- **核心痛点**：世界上有数千种语言，但绝大多数缺乏构建高质量 TTS 所需的大规模“文本-语音”成对数据（Paired data）。
- **主流解法**：
  - **自监督训练（Self-supervised Training）**：利用极易获取的无监督文本或无监督音频进行预训练（如 BERT 增强文本表示，或通过 VQ-VAE 提取离散语音特征）。
  - **跨语言迁移（Cross-lingual Transfer）**：利用发音器官或语义结构的相似性，将资源丰富语言（如英语）学到的声学映射能力迁移到低资源语言中。
  - **语音链与循环一致性（Speech Chain）**：结合自动语音识别（ASR）模型，形成 ASR 与 TTS 的双向互相增强。

3. 鲁棒性提升（Robust TTS）

- **核心痛点**：在长文本或复杂句式下，TTS 模型容易出现**漏读（Word skipping）**、**重复读（Word repeating）**或**注意力崩溃（Attention collapse）**等严重影响可懂度的问题。
- **主流解法**：
  - **增强注意力机制（Enhancing Attention）**：引入单调注意力（Monotonic attention）、局部窗口限制等先验约束，强制模型从左到右对齐。
  - **用时长预测替代注意力（Replacing Attention with Duration）**：如 FastSpeech 模型彻底抛弃编码器-解码器注意力，直接通过提取或预测的音素时长来硬性对齐文本与频谱。

4. 富有表现力的合成（Expressive TTS）

- **核心痛点**：TTS 本质上是一个“一对多映射（One-to-many mapping）”问题（同一句话可以有无数种语气、语速、重音的读法）。如果模型输入信息不足，预测出的声音会倾向于“平均化”（Over-smoothing），导致声音毫无感情、机械平庸。
- **主流解法**：
  - **变化信息的显式与隐式建模**：显式输入音高（Pitch）、能量等特征；或利用参考编码器（Reference Encoder）、全局风格Token（GST）、变分自编码器（VAE）等高级生成模型隐式提取韵律特征。
  - **解耦、控制与迁移（Disentangling, Controlling, Transferring）**：通过对抗训练（Adversarial Training）将音色、内容、情感、环境噪音进行解耦，从而实现精准控制（如用愤怒的语气读搞笑的台词）。

5. 自适应与声音克隆（Adaptive TTS）

- **核心痛点**：如何仅用极少量的目标说话人数据（甚至几秒钟的音频），就能让源模型学会这个人的音色并生成高质量语音?
- **主流解法**：
  - **小样本适应（Few-data Adaptation）**：仅用几分钟甚至几秒的数据进行微调。
  - **参数高效微调（Few-parameter Adaptation）**：如 AdaSpeech，为降低存储成本，对于每个新用户仅微调极少数的条件层归一化（Conditional Layer Normalization）参数和说话人向量。
  - **零样本适应（Zero-shot Adaptation）**：直接通过扬声器编码器提取特征向量（Speaker Embedding）进行克隆，无需更新任何模型参数。