VLMo

VLMO: Unified Vision-Language Pre-Training with Mixture-of-Modality-Experts

1. title && abstract

- 模型结构的优化：提出了一种名为VLMO的统一视觉-语言预训练模型，即模态专家混合（Mixture-of-Modality-Experts, MoME）的Transformer网络架构
- 分阶段预训练策略

2. intro

`写作思路：现有痛点 –> 本文解决方案 –> 训练策略创新`

- 现有主流框架
  - Dual-encoder 浅层交互 检索任务有效
  - Fusion-encoder 深度联合编码 VL分类任务有效
- 通过 MoME 在同一个Transformer块内处理图像、文本以及图文对这三种不同的输入模态
- 考虑到两种主流框架善于不同的任务，为了利用二者的优势，MoME 摒弃了单一的前馈网络（FFN），代之以三个模态专家：用于图像编码的视觉专家（V-FFN）、用于文本编码的语言专家（L-FFN），以及用于图文融合的视觉-语言专家（VL-FFN）

3. method

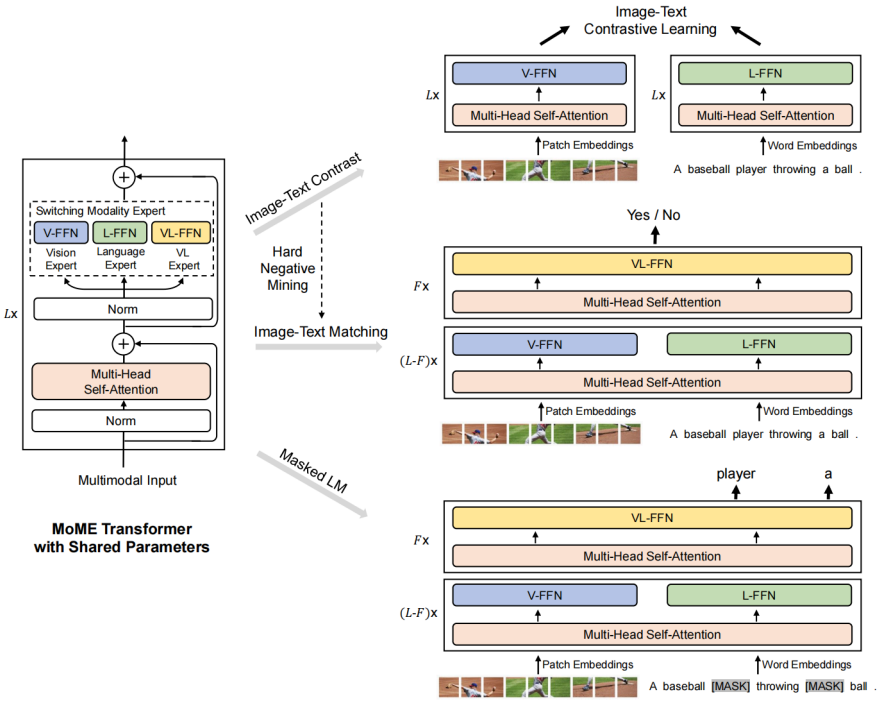

image-157.png

Model Architecture

- **Input Representations**：Vit 的 Image embedding / BERT 中的 WordPiece 分词器 / 图像和文本的输入向量在序列维度上 Concatenate
- **Shared Multi-Head Self-Attention**：无论是输入图像还是文本，自注意力层及其参数在所有模态中都是共享的。这有助于在底层空间对齐视觉和语言的信息特征

? 这里共享 attention 直接输入就可以吗？不需要像ALBEF一样进行对齐吗

- **Switching Modality Expert**：
  - **专家路由 (Expert Routing)**：$MoME\text{-}FFN$ 会根据当前输入数据的模态（纯图、纯文或图文对）以及当前所处的网络层级（l）来自动选择专家 。
  - **V-FFN（视觉专家）**：专门用于处理图像特征
  - **L-FFN（语言专家）**：专门用于处理文本特征
  - **VL-FFN（视觉-语言专家）**：专门负责处理已经过自注意力层初步对齐的、复杂的图文融合特征

Pre- Training

- 网络会根据当前输入数据的三种模态以及网络所在的层数，自动切换并激活对应的专家进行前向传播，借鉴 ALBEF 的

$$\mathcal{L} = \mathcal{L}_{itc} + \mathcal{L}_{mlm} + \mathcal{L}_{itm}$$

  进行预训练，在统一的参数框架下同时执行三种截然不同的预训练任务

? 大多数操作都沿袭 ALBEF 大概是吧？再读一下

Stagewise Pre-Training

- 由于高质量图文对数据规模有限，且文本通常是短小简单的标注，直接用其训练容易导致模型泛化能力不足（经典问题，noisy data）
- **阶段 1 (视觉预训练)**：先用海量纯图像数据，采用 BEIT 提出的掩码图像建模任务，把自注意力模块和 V-FFN 来预热
- **阶段 2 (语言预训练)**：**冻结**刚才练好的自注意力模块和视觉专家，用海量纯文本数据，通过掩码语言建模任务，专门训练 L-FFN
- **阶段 3 (视觉-语言预训练)**：用前两步的参数作为初始化，在图文对数据上全面放开，重点学习模态间的对齐与融合

4. experiment

5. conclusion