变分推理

1. 为什么我们需要变分推理?

在贝叶斯推断中，我们通常假设有一组观测数据 $x = x_{1:n}$ 和一组隐变量 $z = z_{1:m}$ 。我们的终极目标是计算隐变量的**后验分布**：

$$p(z|x,\alpha) = \frac{p(z,x|\alpha)}{\int_z p(z,x|\alpha)}$$

- **困境**：分母需要对所有可能的隐变量进行积分或求和。例如在稍微复杂的模型中，求和的项数可能会呈指数级增长（如 K^n 项），这在数据量 n 较大时在计算上是完全不可行的（Intractable） 。

核心思路：将“积分问题”转化为“优化问题”。 既然算不出真实的后验分布 $p(z|x)$，我们就人为规定一个带有参数 ν 的简单分布族 $q(z_{1:m}|\nu)$ 。然后，我们通过调整参数 ν，在分布族中找到一个与真实后验最接近的 q 。

2. 目标函数：KL 散度与证据下界 (ELBO)

2.1 衡量“接近程度”的标尺：KL 散度

为了衡量 $q(z)$ 与真实后验 $p(z|x)$ 有多接近，使用信息论中的 Kullback-Leibler (KL) 散度 。它的定义为：

$$KL(q||p) = E_q[\log \frac{q(Z)}{p(Z|x)}]$$

目标是**最小化 KL 散度**。但是这里有一个死结：KL 散度的公式里包含了我们根本算不出来的真实后验 $p(Z|x)$ 。

2.2 破局关键：证据下界 (ELBO)

既然不能直接最小化 KL 散度，我们可以利用 Jensen 不等式对观测数据的对数似然 $\log p(x)$ 进行展开：

$$\log p(x) = \log \int_z p(x,z)\frac{q(z)}{q(z)}$$

$$E_q[\log p(x,Z)] - E_q[\log q(Z)]$$

不等式右边的这一项，就被称为**证据下界 (ELBO, Evidence Lower Bound)** 。

为什么优化 ELBO 就等于优化 KL 散度?

$$KL(q(z)||p(z|x)) = E_q \log \frac{q(Z)}{\frac{p(Z,x)}{p(x)}}$$

$$KL(q(z)||p(z|x)) = E_q[\log q(Z)] - E_q[\log p(Z,x)] + E_q[\log p(x)]$$

$$KL(q(z)||p(z|x)) = E_q[\log q(Z)] - E_q[\log p(Z,x)] + \log p(x)$$

$$\log p(x) = \ + KL(q(z)||p(z|x))$$

因为 $\log p(x)$ 是一个与 q 无关的常数，所以**最大化 ELBO 就完全等价于最小化 KL 散度** 。至此，我们成功找到了一个可以实际计算并优化的目标函数。

3. 平均场假设 (Mean-Field Approximation)

为了让 $q(z)$ 足够简单且易于计算，变分推理通常会引入**平均场假设**。该假设认为，在近似分布 q 中，所有的隐变量是相互独立的，即分布可以完全分解：

$$q(z_1, \ , z_m) = \ _{=1}^{m} q(z)$$

⚠️ **教学预警：变分推断的“工程妥协”**

- **牺牲局部换取全局**：真实的后验分布中，隐变量往往是高度相关的 。
- **误区提示**：变分推断（VB）的目的是去逼近**联合分布**，而不是为了精确逼近每个变量的**边缘分布** 。
- **直观例子**：假设我们在估计螺丝的直径均值 μ 和具体某个螺丝的直径 x。真实的联合分布可能是一个斜向的宽椭圆，但因为我们假设了 $q(\mu, x) = q(\mu)q(x)$，变分推断为了最小化自身区域内的误差，会拟合出一个非常紧凑的直立圆 。这就导致单独拿出来的近似边缘分布 $_x(x)$ 会非常窄，与真实的边缘分布 (x) 截然不同 。**在调试模型时，千万不要因为单一节点的边缘分布看起来违反直觉就认为算法写错了** 。

4. 优化算法：坐标上升法 (Coordinate Ascent)

在确定了目标函数（ELBO）和分布形式（平均场）后，我们如何求最优解？ 最常用的方法是**坐标上升变分推断 (CAVI)**：每次固定其他的分布因子，单独更新一个 $q(z)$，不断迭代直到 ELBO 收敛 。

对于变量 z，其最优更新公式为：

$$q(z) \ \ E_{-}[\log p(z, Z_{-}, x)]$$

- **公式解读**：要更新第 个变量的分布，你只需要写出所有变量的联合对数概率，然后求出**除了第 个变量以外**其他所有变量的期望 E_{-}，最后取指数即可 。

5. 进阶视角：变分消息传递 (VMP)

如果你觉得每次都要手推上述公式太繁琐且容易出错 ，在现代工程实践中，对于由共轭指数族（Conjugate-Exponential）构成的概率图模型，我们可以将变分推理自动化 。

这被称为**变分消息传递 (Variational Message Passing, VMP)** 。它的核心思想是： 节点只需要通过计算充分统计量的期望，并将其作为“消息”传递给它的父节点或子节点即可 。这使得大规模复杂模型的变分推断可以通过类似搭积木的方式自动完成 。