Unit5

Unit 5. Automatic speech recognition

Pre-trained models for speech recognition

1. 核心任务：自动语音识别 (ASR)

本 Unit 核心是 **ASR (Automatic Speech Recognition)** —— 把“音频信号”（波形图）转换成“文本序列”（字符串）。

2. 两大技术流派

材料中对比了两种截然不同的深度学习架构，这是理解后续所有代码的基石：

- **CTC (Connectionist Temporal Classification)**
- **Seq2Seq (Sequence-to-Sequence)**

CTC的局限性：

- 纯声学依赖
- 缺乏上下文语境
- 文本格式化问题（大小写、标点符号）

3. Seq2Seq

- Decoder ： 兼具编码器传来的音频特征的解码工作和语言模型的角色，以便更好的预测下一个词
- **缺点**：需要的数据量庞大

4. Seq2seq实战

- **两个缺陷**：
  - Whisper 的 input 通常为30s
  - OOM
- **解决方案：**
  - chunking（分为30s便于处理） + overlap（防止切断某一个单词）

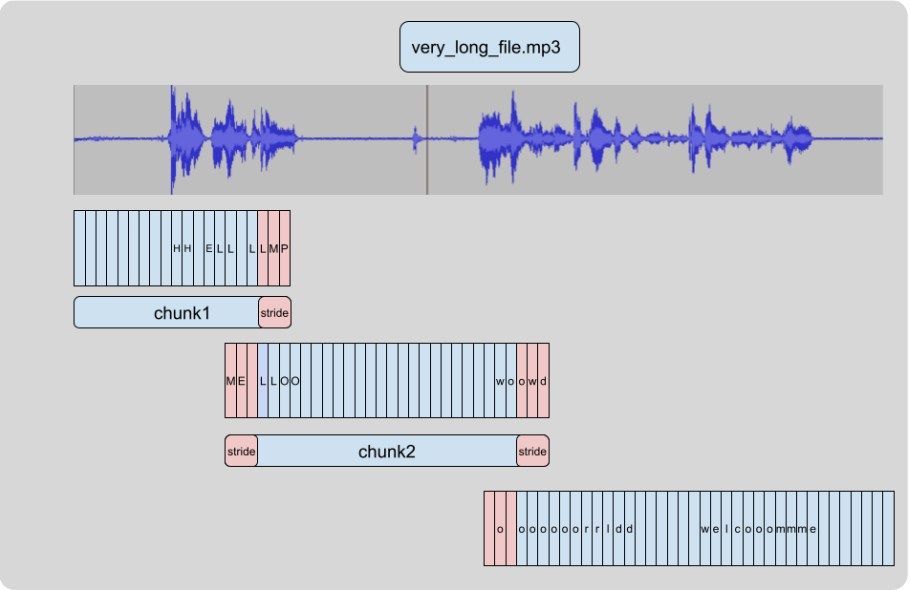

image-170.png

- 先重叠后续再合并相同字母，组成完整句子

Evaluation and metrics for speech recognition

Error Types

在计算评估指标前，模型预测序列与标准参考序列 (Reference) 对齐后，产生的错误严格划分为以下三类（简称 **S.I.D**）：

- **S - 替换 (Substitution)**: 识别成错误的词（例如：`sat` → `sit`）。
- **I - 插入 (Insertion)**: 凭空多识别出的词（无中生有）。
- **D - 删除 (Deletion)**: 漏识别的词（标答有，但没预测出来）。

1. 词错误率 (Word Error Rate, WER)

- **定位**: ASR 领域最权威、最通用的准确度评估事实标准。
- **计算公式**:

$$WER = \frac{S + I + D}{N}$$

  *(注：N 为标准答案 Reference 中的 **总词数（以word为最小粒度）**)*

- **核心特性**:
  - **越低越好**：完美识别时 $WER = 0$。
  - **无上限 (No Upper Limit)**：由于 I（插入错误）的存在，预测的词数可能远超参考词数，因此 WER 完全可以 $> 100\%$。
  - **极度严苛**（比CER更严苛）：只要单词中拼错一个字母，整个单词即被判定为 S。
- **衍生指标**: **CER (Character Error Rate, 字符错误率)**。计算逻辑与 WER 相同，但粒度从“词”变为“字符”。常用于评估中文、日文等无明显空格分词的语言。

2. 逆实时率 (Inverse Real-Time Factor, RTFx)

- **定位**: 衡量 ASR 系统处理速度和工程落地可行性的核心指标。
- **计算公式**:

$$\text{RTFx} = \frac{\text{Audio Duration}}{\text{Processing Time}}$$

  (即：音频总时长 / 模型处理耗时)
- **核心特性**:
  - **越高越好**：代表处理速度越快。
  - **工程基准线**：
    - $\text{RTFx} > 1.0$：处理速度快于音频播放速度，满足**流式/实时场景**（如实时会议字幕）。
    - $\text{RTFx} < 1.0$：处理耗时大于音频时长，仅适用于**离线转录场景**。

工业界核心痛点与对策

- **痛点 (Data Mismatch)**：大小写（如 `Mr.` vs `mr`）和标点符号的存在，会导致计算 WER 时产生大量的伪错误，致使 WER 虚高。
  - **Example**：
    - **标准答案**：`mr. smith goes to washington`
    - **模型预测**：`Mr. Smith goes to Washington.`
- **解决方案 (Text Normalization)**：在输入 WER 计算脚本前，必须进行**文本正则化**。
  - 统一转换为小写
  - 剔除所有标点符号
  - 清理多余的空格